

时间序列分析考纲（基于 11 个文档全覆盖）

一、绪论（文档 10：绪论.pdf）

1.1 时间序列基本概念

- 时间序列的定义：按时间顺序排列的观察值序列 / 随机序列及其关系（观察值是随机序列的实现）
- 时间序列的分类：单变量 / 多变量、平稳 / 非平稳、周期性 / 非周期性
- 时间序列分析的核心目标：通过观察值序列推断随机序列的性质与概率分布

1.2 时间序列分析流程与应用

- 经典分析流程：数据预处理→模型识别→参数估计→模型检验→预测 / 应用
- 典型应用场景：经济数据（GDP）、金融数据（股价）、工业数据（产量）、环境数据（温度）

二、时间序列的随机过程基础与平稳性（文档 1：ch04.pdf）

2.1 时间序列的概率化定义

- 随机序列与观察值序列的数学表达 ($\cdots, Y_1, Y_2, \cdots, Y_t, \cdots$ 与 y_1, y_2, \cdots, y_n)
- 随机过程的定义： $Y(t, \omega)$ （时间 $t \in T$ 、实现 $\omega \in \Omega$ ）及有限维联合分布族

2.2 平稳性定义与判别

- 严平稳（Strongly Stationary）：有限维联合分布不随时间平移变化的数学条件
- 宽平稳（Weakly Stationary）：1-2 阶矩不随时间变化 ($\mu(t) = \mu$ 、 $\sigma^2(t) = \sigma^2$ 、 $\gamma(t_1, t_2) = \gamma(t_1 - t_2)$)
- 严平稳与宽平稳的关系：严平稳→宽平稳（需存在 1-2 阶矩），反之不成立

2.3 时间序列核心统计量

- 序列均值： $\mu(t)=E[Y(t)]$ ；宽平稳下 $\mu(t)=\mu$
- 自协方差函数： $\gamma(t_1,t_2)=Cov[Y(t_1),Y(t_2)]$ ；宽平稳下 $\gamma(k)=Cov[Y_t,Y_{t+k}]$
- 自相关系数（ACF）： $\rho(k)=\frac{\gamma(k)}{\gamma(0)}$ ，性质（对称性、规范性 $|\rho(k)|\leq 1$ 、非负定性）

2.4 特殊随机过程与分解定理

- 纯随机序列（白噪声）： $WN(0,\sigma^2)$ 的定义、均值 / 方差 / 自协方差 / 自相关系数性质
- Wold 分解定理：平稳序列分解为确定性序列 V_t 与随机性序列 ξ_t （白噪声线性组合）
- Cramer 分解定理：序列波动的确定性（多项式趋势）与随机性分解，差分提取确定性信息
- 延迟算子（B）：定义（ $BY_t=Y_{t-1}$ ）、性质（线性、幂次）与差分表示（ $\nabla=(1-B)$ ）

三、线性过程与 AR/MA/ARMA/ARIMA 模型（文档 2： ch05.pdf）

3.1 线性过程

- 定义： $Y_t=\sum_{i=0}^{\infty}\psi_i\varepsilon_{t-i}$ （ ε_t 为白噪声， $\psi_0=1$ ）
- 平稳性条件： $\sum_{i=0}^{\infty}|\psi_i|<\infty$ （或生成函数 $\psi(z)$ 在 $|z|>1$ 收敛）
- 可逆性条件： $\pi(B)Y_t=\varepsilon_t$ 中 $\pi(z)$ 在 $|z|>1$ 收敛

3.2 AR 模型（自回归模型）

- 定义：AR(p)模型 $Y_t=\phi_0+\sum_{i=1}^p\phi_iY_{t-i}+\varepsilon_t$ （中心化 $\phi_0=0$ ），延迟算子表示 $\Phi(B)Y_t=\varepsilon_t$
- 平稳性判别：
 - 特征根判别：特征方程 $\lambda^p-\phi_1\lambda^{p-1}-\dots-\phi_p=0$ 的根全在单位圆内
 - 平稳域：AR(1) ($|\phi_1|<1$)、AR(2) ($|\phi_2|<1, \phi_2\pm\phi_1<1$)
- 统计性质：均值 $\mu=\frac{\phi_0}{1-\sum_{i=1}^p\phi_i}$ 、方差 $\sigma_Y^2=\frac{\sigma_\varepsilon^2}{1-\sum_{i=1}^p\phi_i^2}$ （AR(1)）、自相关函数拖尾、偏自相关函数 p 阶截尾

3.3 MA 模型（移动平均模型）

- 定义：MA(q)模型 $Y_t = \mu + \varepsilon_t + \sum_{i=1}^q \theta_i \varepsilon_{t-i}$ ，延迟算子表示 $Y_t = \Theta(B)\varepsilon_t$
- 可逆性条件：特征方程 $\lambda^q - \theta_1 \lambda^{q-1} - \dots - \theta_q = 0$ 的根全在单位圆内（或 $\Theta(z)=0$ 根在单位圆外）
- 统计性质：均值 μ 、方差 $\sigma_Y^2 = (1 + \sum_{i=1}^q \theta_i^2) \sigma_{\varepsilon}^2$ 、自相关函数 q 阶截尾、偏自相关函数拖尾

3.4 ARMA 模型（自回归移动平均模型）

- 定义：ARMA(p,q)模型 $\Phi(B)Y_t = \Theta(B)\varepsilon_t$ ，平稳性由 AR 部分决定，可逆性由 MA 部分决定
- 统计性质：均值 $\mu = \frac{\phi_0}{1 - \sum_{i=1}^p \phi_i}$ 、自相关 / 偏自相关函数均拖尾

3.5 ARIMA 模型（差分自回归移动平均模型）

- 定义：ARIMA(p,d,q)模型： $\Phi(B)\nabla^d Y_t = \Theta(B)\varepsilon_t$ （ ∇^d 为 d 阶差分）
- 差分阶数 d 的意义：将非平稳序列转化为平稳序列（如随机游走 ARIMA(0,1,0)）

3.6 模型预测

- 最优预测准则：最小化均方误差，最优预测为条件期望 $\hat{Y}_{t+k|t} = E[Y_{t+k} | Y_t, Y_{t-1}, \dots]$
- 预测误差： $e_{t+k|t} = Y_{t+k} - \hat{Y}_{t+k|t}$ ，方差 $\sigma_k^2 = (1 + \sum_{i=1}^{k-1} \psi_i^2) \sigma_{\varepsilon}^2$
- 递推预测：基于差分方程的递归公式（ARMA/ARIMA 模型）

四、时间序列模型的检验、拟合与拓展（文档 3：ch06.pdf）

4.1 模型定阶（确定 p,d,q）

-

差分阶数 d 的识别：ACF 衰减速度（慢则需差分）、过差分判断（引入不必要相关性）、单位根检验（KPSS）

- ARMA (p,q) 的 p,q 确定：ACF（MA (q) 截尾）、PACF（AR (p) 截尾）、样本 ACF/PACF 图分析

4.2 模型参数估计

- 矩估计：基于样本均值、自协方差估计参数（如 AR (p) 的 Yule-Walker 方程组）
- 最小二乘估计（LS）：AR (p) 模型最小化残差平方和 $S(\theta) = (Y - X\theta)^T(Y - X\theta)$ ，求解 $\hat{\theta} = (X^T X)^{-1} X^T Y$
- 极大似然估计（ML）：假设高斯过程，构造条件似然函数，优化参数使似然最大

4.3 模型选择准则

- AIC: $AIC_{p,q} = -2 \ln L + 2r \approx n \ln(\hat{\sigma}_a^2) + \frac{2r}{n}$ ($r = p + q + 1$)
- AICc（修正 AIC）: $AICc = AIC + \frac{2r(r+2)}{n(r+1)}$ （小样本修正）
- BIC: $BIC = n \ln(\hat{\sigma}_a^2) + r \ln n$ （更惩罚多参数）

4.4 假设检验

- 纯随机检验（模型显著性）：
 - Box-Pierce 检验: $Q = n \sum_{k=1}^{\ell} r_k^2$
 - Ljung-Box 检验: $Q^* = n(n+2) \sum_{k=1}^{\ell} \frac{r_k^2}{n-k}$ （更适小样本）
- 平稳性检验：
 - DF/ADF 检验：原假设存在单位根（非平稳）
 - KPSS 检验：原假设序列平稳

4.5 模型拓展

- 动态回归模型：结合线性回归与 ARIMA, $y_t = \beta_0 + \sum_{i=1}^k \beta_i x_{i,t} + \eta_t$ (η_t 为 ARIMA 过程)
- 传递函数模型: $Y_t = \frac{\omega(B)}{\delta(B)} B^b X_t + \frac{\theta(B)}{\varphi(B)} \varepsilon_t$
- ARMAX 模型（带外生输入的 ARMA）: $\varphi(B)Y_t = \omega(B)X_{t-b} + \theta(B)\varepsilon_t$
-

干预模型：处理外部事件影响， $Y_t = \frac{\omega(B)}{\delta(B)}I_t + \frac{\theta(B)}{\phi(B)}\varepsilon_t$ (I_t 为干预变量)

- ARCH 模型：条件异方差， $\sigma_t^2 = \alpha_0 + \sum_{i=1}^s \alpha_i \varepsilon_{t-i}^2$ ($\varepsilon_t = \sigma_t \varepsilon_t$)

五、季节性时间序列分析（文档 4：ch07.pdf）

5.1 时间序列因素分解

- 四大因素：长期趋势（T）、循环波动（C）、季节变化（S）、随机波动（I）
- 分解模型：
 - 加法模型： $Y_t = T_t + C_t + S_t + I_t$ （趋势与季节振幅无关）
 - 乘法模型： $Y_t = T_t \times C_t \times S_t \times I_t$ （趋势与季节振幅相关）

5.2 季节效应提取

- 加法模型季节指数： $S_j = \bar{y}_j - \bar{y}$ (\bar{y}_j 为季度均值， \bar{y} 为总均值)
- 乘法模型季节指数： $S_j = \frac{\bar{y}_j}{\bar{y}}$

5.3 经典季节调整模型

- X11 模型：Henderson 加权移动平均（提取趋势）、Musgrave 非对称移动平均（补充边界）、多轮迭代分解
- SEATS：基于 ARIMA 的季节提取
- STL 分解（LOESS-based）：
 - 内循环：去趋势→周期子序列平滑→低通滤波→去趋势（季节成分）→去季节→趋势平滑
 - 外循环：计算鲁棒权重，修正异常值

5.4 季节性 ARIMA 模型（SARIMA）

- 定义：SARIMA(p,d,q)(P,D,Q)_S，包含非季节性（p,d,q）与季节性（P,D,Q,S）部分
- 模型形式： $\Phi(B^S)\phi(B)\nabla_S^D\nabla^dY_t = \Theta(B^S)\theta(B)\varepsilon_t$ ($\nabla_S = 1 - B^S$ 为季节差分)

5.5 Prophet 方法

- 序列分解: $y(t)=g(t)+s(t)+h(t)+\epsilon_t$ ($g(t)$ 趋势、 $s(t)$ 周期、 $h(t)$ 假日效应)
- 趋势建模: 逻辑增长模型 $g(t)=\frac{C(t)}{1+\exp(-k(t-m))}$ (含变化点)
- 周期建模: 傅里叶级数 $s(t)=\sum_{n=1}^N(a_n\cos(\frac{2\pi nt}{P})+b_n\sin(\frac{2\pi nt}{P}))$
- 假日建模: 基于节假日列表构造虚拟变量 $Z(t)$, $h(t)=Z(t)\kappa$

六、状态空间模型与机器学习预测 (文档 5: ch08.pdf)

6.1 状态空间模型

- 定义:
 - 系统方程: $X_t=AX_{t-1}+Bu_{t-1}+e_{1,t}$ (状态转移)
 - 观测方程: $Y_t=CX_t+e_{2,t}$ (观测生成)
- 可观测性: $\text{rank}[C^T:(CA)^T:\cdots:(CA^{m-1})^T]=m$ (m 为状态维度)

6.2 卡尔曼滤波

- 核心思想: 基于观测更新状态估计, 最小化均方误差
- 递推公式:
 - 预测: $\hat{X}_{t+1|t}=A\hat{X}_{t|t}+Bu_t$, $\sum_{t+1|t}^{xx}=A\sum_{t|t}^{xx}A^T+\sum_1$
 - 重构: $K_t=\sum_{t|t-1}^{xx}C^T(\sum_{t|t-1}^{yy})^{-1}$, $\hat{X}_{t|t}=\hat{X}_{t|t-1}+K_t(Y_t-C\hat{X}_{t|t-1})$

6.3 机器学习预测方法

- 回归模型: MLP、BNN、RBF、GRNN、KNN、CART、SVR、GP (性能对比: MLP 通常最优)
- 降维方法: PCA (多元时序降维为少数无关序列)、张量拓展 (TensorCast)
- 集成学习:
 - Residual 集成: 用二次网络学习一次模型残差
 - MOE (混合专家): 多模型加权集成

- GBRT (XGBoost/LightGBM/CatBoost) : 窗口化回归任务
- 多步预测策略:
 - 递归预测 (Recursive) : 用前一步预测值作为下一步输入
 - 直接预测 (Direct) : 为每个步长训练独立模型
 - 混合策略 (DirREC) : 结合递归与直接

6.4 竞赛实践 (M5 竞赛)

- 数据特点: 42840 个零售销售时序 (分层结构)
- 核心方法: LightGBM 集成 (按商店 / 品类 / 部门分组训练)、Tweedie 损失 (处理零膨胀数据)

七、时间序列深度学习模型 (文档 6: ch09.pdf)

7.1 序列模型 (RNN/LSTM)

- RNN: 定义 $h_t = \tanh(W_{hh}h_{t-1} + W_{hx}x_t)$, 缺点 (梯度消失 / 爆炸)
- LSTM: 通过输入门、遗忘门、输出门解决长程依赖, $c_t = f \odot c_{t-1} + i \odot g$, $h_t = o \odot \tanh(c_t)$
- DeepAR: 基于 LSTM 的概率预测, 假设高斯 / 负二项似然
- MQ-RNN: 多 horizon 分位数预测, 最小化分位数损失 $L_q(y, \hat{y}) = q(y - \hat{y})_+ + (1-q)(\hat{y} - y)_+$

7.2 卷积模型 (TCN)

- 核心组件: 因果卷积 (无未来信息泄露)、膨胀卷积 (扩大感受野)、残差连接
- 优势: 并行计算、可变感受野、低内存

7.3 注意力模型 (Transformer)

- 自注意力: $\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$, 位置编码 (正弦 / 余弦或可学习)
- 变体:
 - LogSparse: 缓解内存瓶颈 ($O(L \log L)$ 复杂度)

- Informer: ProbSparse 自注意力，生成式解码
- AutoFormer: 基于自相关的分解 Transformer

7.4 其他深度学习模型

- N-BEATS: 基于残差块的可解释模型，分解趋势（多项式）与季节（傅里叶）成分
- NHITS: 分层插值，多尺度采样降低计算量
- LSTNet: 结合 CNN（提取短期模式）与 RNN（长期依赖），AR 组件修正

7.5 混合与集成模型

- 混合模型（ES-RNN）：指数平滑（去季节趋势）+LSTM（预测）
- 模型集成（FFORMA）：元学习选择模型权重，基于时序特征（趋势强度、季节性等）
- 数据增强：时间域（裁剪、抖动）、频率域（傅里叶变换）、生成模型（GAN）

八、进阶线性模型与归一化（文档 7: ch10.pdf）

8.1 进阶线性模型

- DLinear: 分解序列为趋势与残差，分别线性建模
- RLinear: RevIN+MLP + 通道独立（CI）策略
- TSMixer: 全 MLP 架构，含时间混合与特征混合模块

8.2 归一化方法

- RevIN（可逆实例归一化）：
$$\hat{x}_{kt}^{(i)} = \gamma_k \left(\frac{x_{kt}^{(i)} - \mu_{kt}^{(i)}}{\sqrt{\sigma_{kt}^{(i)^2} + \epsilon}} \right) + \beta_k$$
，预测后反归一化
- SAN（切片自适应归一化）：按切片统计量归一化，预测切片统计量
- SIN（选择性可解释归一化）：最大化局部不变性与全局变异性，基于 SVD 学习归一化参数

8.3 通道策略（CI vs CD）

- 通道依赖（CD）：多元预测多元，依赖通道间关联

- 通道独立 (CI)：视为多个一元任务，缓解分布漂移，提升鲁棒性

8.4 Transformer 变体

- PathTST：patch 嵌入 + 通道独立 + Transformer，减少输入 token 数
- CrossFormer：维度分段嵌入 (DSW)，两阶段注意力 (跨时间、跨维度)
- iTransformer：反转时序与通道维度，注意力作用于通道
- SOFTS：系列核心融合，线性复杂度 ($O(CL+CH)$)

九、时序表示学习与通用模型 (文档 8: ch11.pdf)

9.1 自监督时序表示学习

- Unsupervised Scalable：对比学习，拉近参考子序列与正子序列表示，拉远负子序列
- TS2Vec：时间对比损失 (同时间戳不同视图为正) + 实例对比损失 (其他序列为负)，支持分类 / 预测 / 异常检测
- CoST：解纠缠趋势与季节表示，时间域 + 频率域 (振幅、相位) 对比损失
- SimMTM：掩码时序建模，通过邻域聚合恢复掩码点，结合重构与对比损失

9.2 通用任务模型

- TimesNet：建模时序 2D 变化 (intra-period/inter-period)，支持长短期预测、分类、异常检测
- Meta-Transformer：统一多模态输入 (文本、图像、时序)，映射到共享 token 空间，冻结编码器提取特征

9.3 通用预测模型

- 零样本预测：基于元学习，无需特定任务训练
- 少样本预测：利用相似序列信息，迁移学习

十、时间序列评价与预处理 (文档 11: 时间序列评价和预处理.pdf)

10.1 数据预处理

- 缺失值处理：插值（线性、样条）、模型预测（ARIMA）、删除（样本量充足）
- 异常值检测与处理：
 - 检测： 3σ 准则、IQR、LOF（局部离群因子）
 - 处理：替换（均值 / 中位数）、删除、修正（基于邻域）
- 数据转换：
 - Box-Cox 变换： $y^{(\lambda)} = \begin{cases} \frac{y^{\lambda-1}}{\lambda} & \lambda \neq 0 \\ \ln y & \lambda = 0 \end{cases}$ （稳定方差）
 - 归一化 / 标准化：Min-Max ($x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$)、Z-Score ($x' = \frac{x - \mu}{\sigma}$)

10.2 评价指标

- 误差指标：
 - MAE（平均绝对误差）： $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$
 - MSE（均方误差）： $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
 - RMSE（均方根误差）： $RMSE = \sqrt{MSE}$
- 相对误差指标：
 - SMAPE（对称平均绝对百分比误差）： $SMAPE = \frac{2}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|} \times 100\%$
 - MAPE（平均绝对百分比误差）： $MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{|y_i|} \times 100\%$ （避免 $y_i = 0$ ）
- 综合指标：
 - OWA（总体权重误差）：综合多个指标的加权得分
 - MASE（平均绝对标度误差）： $MASE = \frac{MAE}{\frac{1}{n-1} \sum_{i=2}^n |y_i - y_{i-1}|}$ （基准为朴素预测）

十一、时间序列基础预测方法（文档 12：时间序列的基础预测方法.pdf）

11.1 朴素预测方法

- 朴素预测： $\hat{y}_{t+k}=y_t$ （无趋势无季节）
- 带漂移的朴素预测： $\hat{y}_{t+k}=y_t+k\times\frac{y_t-y_{t-1}}{t-1}$ （线性趋势）
- 季节朴素预测： $\hat{y}_{t+k}=y_{t+k-S}$ （S 为周期）

11.2 滑动平均预测

- 简单滑动平均（SMA）： $\hat{y}_{t+1}=\frac{y_t+y_{t-1}+\cdots+y_{t-m+1}}{m}$ （m 为窗口）
- 加权滑动平均（WMA）： $\hat{y}_{t+1}=\frac{w_my_t+w_{m-1}y_{t-1}+\cdots+w_1y_{t-m+1}}{\sum_{i=1}^mw_i}$ （近期权重高）

11.3 指数平滑预测

- 简单指数平滑（SES）： $S_t=\alpha y_t+(1-\alpha)S_{t-1}$ ， $\hat{y}_{t+k}=S_t$ （无趋势无季节， $\alpha\in(0,1)$ ）
- Holt 线性趋势平滑： $S_t=\alpha y_t+(1-\alpha)(S_{t-1}+T_{t-1})$ ， $T_t=\beta(S_t-S_{t-1})+(1-\beta)T_{t-1}$ ， $\hat{y}_{t+k}=S_t+kT_t$ （线性趋势）
- Holt-Winters 季节平滑：
 - 加法： $S_t=\alpha\frac{y_t}{I_{t-S}}+(1-\alpha)(S_{t-1}+T_{t-1})$ ， $T_t=\beta(S_t-S_{t-1})+(1-\beta)T_{t-1}$ ， $I_t=\gamma\frac{y_t}{S_t}+(1-\gamma)I_{t-S}$
 - 乘法： $S_t=\alpha(y_t-I_{t-S})+(1-\alpha)(S_{t-1}+T_{t-1})$ ，其余同加法

11.4 趋势外推预测

- 线性趋势： $\hat{y}_t=a+bt$ （最小二乘估计 a,b）
- 指数趋势： $\hat{y}_t=ab^t$ （对数转换为线性）
- 多项式趋势： $\hat{y}_t=a+bt+ct^2+\cdots+dt^p$ （p 次多项式）

时间序列知识点分类（记忆 / 推导 / 实操）

一、绪论（文档 10）

记忆类

- 1. 时间序列的定义（观察值序列 / 随机序列）及关系
- 2. 时间序列的分类（单变量 / 多变量、平稳 / 非平稳、周期性 / 非周期性）
- 3. 时间序列分析的经典流程（数据预处理→模型识别→参数估计→模型检验→预测）
- 4. 典型应用场景（经济、金融、工业、环境）

推导类

无（绪论以概念为主）

实操类

- 1. 识别给定数据的时间序列类型（如判断是否含季节趋势）
- 2. 梳理具体问题的时间序列分析流程（如 GDP 数据的分析步骤）

二、时间序列的随机过程基础与平稳性（文档 1）

记忆类

- 1. 严平稳、宽平稳的定义及数学条件
- 2. 时间序列统计量（均值、自协方差、自相关系数）的定义及宽平稳下的性质
- 3. 白噪声序列（WN）的定义、均值 / 方差 / 自协方差 / 自相关系数性质
- 4. Wold 分解、Cramer 分解的核心结论（平稳序列的分解形式）
- 5. 延迟算子（B）的定义及性质（ $B^k Y_t = Y_{t-k}$ 、线性性）
- 6. 差分算子的定义（一阶 $\nabla = 1 - B$ 、p 阶 $\nabla^p = (1 - B)^p$ 、季节差分 $\nabla_S = 1 - B^S$ ）

推导类

- 1.

宽平稳序列自协方差函数的对称性 ($\gamma(k)=\gamma(-k)$)、规范性 ($|\gamma(k)|\leq\gamma(0)$) 推导

- 2. 自相关系数性质 ($\rho(0)=1$ 、 $|\rho(k)|\leq 1$) 推导
- 3. Cramer 分解下 d 阶差分提取多项式趋势的推导 (如 $\nabla^d \sum_{j=0}^d \beta_j t^j = c$)
- 4. 延迟算子展开差分表达式 (如 $\nabla^2 Y_t = (1-2B+B^2)Y_t$)

实操类

- 1. 计算给定平稳序列的样本均值、样本自协方差、样本自相关系数
- 2. 绘制自相关函数 (ACF) 图，判断序列是否为白噪声
- 3. 对非平稳序列 (如含线性趋势) 进行差分操作，观察平稳性变化

三、线性过程与 AR/MA/ARMA/ARIMA 模型 (文档 2)

记忆类

- 1. 线性过程的定义及平稳性、可逆性的直观理解
- 2. AR (p)、MA (q)、ARMA (p,q)、ARIMA (p,d,q) 的定义及延迟算子表示
- 3. AR 模型平稳性的特征根判别法、平稳域 (AR (1): $|\phi_1|<1$; AR(2): $|\phi_2|<1, \phi_2 \neq \phi_1$)
- 4. MA 模型可逆性的定义及判别条件 (特征根在单位圆内)
- 5. 各模型自相关函数 (ACF)、偏自相关函数 (PACF) 的特征 (AR (p): PACF p 阶截尾、ACF 拖尾; MA (q): ACF q 阶截尾、PACF 拖尾; ARMA (p,q): 均拖尾)
- 6. ARIMA 模型中差分阶数 d 的意义 (将非平稳转为平稳)

推导类

- 1. AR (1) 模型的平稳性推导 (特征根 $\lambda=\phi_1$, 需 $|\lambda|<1$)
- 2. AR (1) 模型的均值 ($\mu=0$, 中心化)、方差 ($\sigma_Y^2=\frac{\sigma_{\epsilon}^2}{1-\phi_1^2}$)、自协方差 ($\gamma(k)=\phi_1^{|k|}\gamma(0)$)、自相关系数 ($\rho(k)=\phi_1^{|k|}$) 推导
- 3. MA (1) 模型的均值 (μ)、方差 ($\sigma_Y^2=(1+\theta_1^2)\sigma_{\epsilon}^2$)、自相关系数 ($\rho(1)=\frac{-\theta_1}{1+\theta_1^2}$, $k>1$ 时 $\rho(k)=0$) 推导

4. ARMA (1,1) 模型的自协方差函数推导
5. ARIMA 模型预测的条件期望 ($\hat{Y}_{t+k|t} = E[Y_{t+k} | Y_t, Y_{t-1}, \dots]$) 及预测误差方差推导

实操类

1. 用特征根判别法判断给定 AR (1)/AR (2) 模型的平稳性
2. 用 ACF/PACF 图确定 ARMA 模型的 p 和 q (如 ACF1 阶截尾 \rightarrow MA (1))
3. 对非平稳序列 (如随机游走) 确定差分阶数 d, 构建 ARIMA 模型
4. 计算 AR (1) 模型的 k 步预测值及预测误差方差

四、时间序列模型的检验、拟合与拓展 (文档 3)

记忆类

1. 模型定阶方法: d 的识别 (ACF 衰减速度、KPSS 检验)、p/q 的确定 (ACF/PACF 特征)
2. 参数估计方法: 矩估计、最小二乘 (LS)、极大似然 (ML) 的适用场景
3. 模型选择准则: AIC、AICc、BIC 的公式及特点 (AICc 小样本修正, BIC 更惩罚多参数)
4. 纯随机检验: Box-Pierce (Q 统计量)、Ljung-Box (Q^* 统计量) 的原假设与拒绝条件
5. 平稳性检验: DF/ADF (原假设非平稳)、KPSS (原假设平稳) 的核心思想
6. 拓展模型: 动态回归、ARMAX、干预模型、ARCH 的定义及适用场景

推导类

1. AR (p) 模型矩估计的 Yule-Walker 方程组推导 (如 AR (2) 的 $\rho_1 = \phi_1 + \phi_2 \rho_1$, $\rho_2 = \phi_1 \rho_1 + \phi_2$)
2. AR (p) 模型最小二乘估计的残差平方和最小化推导 ($\hat{\theta} = (X^T X)^{-1} X^T Y$)
3. ARMA 模型条件似然函数的构建推导 (基于高斯假设)
4. Box-Pierce 统计量的渐近分布 ($\chi^2(\ell-p-q)$) 推导思路
5. ARCH 模型条件方差 ($\sigma_t^2 = \alpha_0 + \sum_{i=1}^s \alpha_i \epsilon_{t-i}^2$) 的平稳性条件 ($\sum_{i=1}^s \alpha_i < 1$) 推导

实操类

1. 对给定序列计算样本 ACF/PACF，确定 ARMA (p,q) 的 p 和 q
2. 用矩估计 / 最小二乘估计 AR (1)/AR (2) 模型的参数
3. 计算 Box-Pierce/Ljung-Box 统计量，检验模型残差是否为白噪声
4. 用 ADF/KPSS 检验序列平稳性
5. 对含外生变量的序列（如销量 + 促销活动）构建动态回归模型

五、季节性时间序列分析（文档 4）

记忆类

1. 时间序列四大因素（趋势 T、循环 C、季节 S、随机 I）的定义
2. 加法 / 乘法分解模型的适用场景（加法：趋势与季节振幅无关；乘法：相关）
3. X11 模型的核心步骤（Henderson 移动平均、Musgrave 修正、多轮迭代）
4. STL 分解的内循环、外循环步骤及 LOESS 的作用
5. SARIMA 模型的定义（SARIMA(p,d,q)(P,D,Q)_S）及延迟算子表示
6. Prophet 方法的序列分解形式 ($y(t)=g(t)+s(t)+h(t)+\epsilon_t$) 及各成分建模方式

推导类

1. 加法模型季节指数 ($S_j = \bar{y}_j - \bar{y}$) 的计算推导
2. 乘法模型季节指数 ($S_j = \frac{\bar{y}_j}{\bar{y}}$) 的计算推导
3. STL 分解中 LOESS 局部回归的损失函数（加权最小二乘）推导思路
4. SARIMA 模型中季节差分 (∇_S^D) 提取季节趋势的推导

实操类

1. 对含季节趋势的序列（如月度销量）选择加法 / 乘法模型，提取季节指数
2. 用 X11/STL 分解工具（如 R 的 `seasonal` 包、Python 的 `statsmodels`）分解序列

3. 构建 SARIMA 模型对季节性序列进行预测
4. 用 Prophet 工具 (Python 的 prophet 库) 预测含趋势、季节、假日效应的序列 (如电商销量)

六、状态空间模型与机器学习预测 (文档 5)

记忆类

1. 状态空间模型的系统方程、观测方程定义及各变量含义
2. 可观测性的定义及判别条件 (秩条件)
3. 卡尔曼滤波的核心功能: 状态重构、一步预测、多步预测
4. 常用机器学习预测模型 (MLP、KNN、SVR、GP) 的适用场景及特点
5. 集成学习方法 (Residual、MOE、GBRT) 的核心思想
6. 多步预测策略 (递归、直接、DirREC) 的优缺点

推导类

1. 卡尔曼滤波的预测递推公式 ($\hat{X}_{t+1|t} = A\hat{X}_{t|t} + Bu_t$, $\sum_{t+1|t}^{xx} = A\sum_{t|t}^{xx}A^T + \sum_1$) 推导
2. 卡尔曼滤波的状态重构公式 ($\hat{X}_{t|t} = \hat{X}_{t|t-1} + K_t(Y_t - C\hat{X}_{t|t-1})$) 及卡尔曼增益 K_t 推导
3. 线性回归模型 (如 KNN) 的距离度量 (欧氏距离) 及权重计算推导
4. GBRT 的梯度提升步骤 (残差计算、弱学习器训练、权重更新) 推导思路

实操类

1. 对简单系统 (如自由落体) 构建状态空间模型, 写出系统 / 观测方程
2. 用卡尔曼滤波递推公式计算状态的预测值与重构值 (如温度监测数据)
3. 用 Python 的 scikit-learn 实现 MLP/KNN/SVR 模型, 对时序数据进行预测
4. 对比不同多步预测策略的预测误差 (如对股价数据用递归 vs 直接预测)
5. 用 LightGBM 构建集成模型, 处理多变量时序数据 (如电力负荷预测)

七、时间序列深度学习模型（文档 6）

记忆类

1. RNN 的结构（隐藏状态更新公式）及梯度消失 / 爆炸问题
2. LSTM 的门结构（输入门、遗忘门、输出门）及状态更新公式
3. TCN 的核心组件（因果卷积、膨胀卷积、残差连接）及优势
4. Transformer 自注意力机制的公式及位置编码的作用
5. N-BEATS 的残差块结构及趋势 / 季节成分的建模方式
6. 混合模型（ES-RNN）、集成模型（FFORMA）的核心思想

推导类

1. RNN 隐藏状态的反向传播梯度计算（解释梯度消失原因）
2. LSTM 细胞状态 $c_t = f \odot c_{t-1} + i \odot g$ 的推导（基于门控机制）
3. Transformer 自注意力权重 $(\text{softmax}(\frac{QK^T}{\sqrt{d_k}}))$ 的推导
4. N-BEATS 趋势成分（多项式）、季节成分（傅里叶级数）的拟合推导
5. FFORMA 元学习权重的损失函数 $(\min_w \sum_n \sum_{m \in \mathcal{M}_n} w_m (f_n - \hat{f}_n)^2)$ 推导

实操类

1. 用 PyTorch/TensorFlow 实现简单 RNN/LSTM 模型，对时序数据（如气温）预测
2. 构建 TCN 模型，调整膨胀系数观察感受野变化
3. 用 transformers 库实现 Transformer 模型，处理长序列（如股票数据）
4. 用 N-BEATS 模型分解时序数据的趋势与季节成分
5. 实现 ES-RNN 混合模型，对比纯 ES、纯 LSTM 的预测效果

八、进阶线性模型与归一化（文档 7）

记忆类

1. DLinear、RLinear 的模型结构（分解趋势 / 残差、RevIN+MLP）
2. 归一化方法（RevIN、SAN、SIN）的核心思想及适用场景
3. 通道独立（CI）与通道依赖（CD）的定义及优缺点（CI 缓解分布漂移）
4. Transformer 变体（PathTST、CrossFormer、iTransformer）的核心改进

推导类

1. RevIN 的归一化与反归一化公式推导（保证可逆性）
2. SIN 的目标函数（最大化局部不变性 L_{loc} 与全局变异性 L_{glo} ）推导
3. CI 策略下线性模型的损失函数（ $\mathcal{L}_{\text{ci}} = \|A_{\text{ci}}W_{\text{ci}} - B_{\text{ci}}\|_F^2$ ）推导
4. PathTST 的 patch 嵌入维度计算推导

实操类

1. 对给定序列用 DLinear 分解趋势与残差，分别建模预测
2. 实现 RevIN 归一化，对比归一化前后模型（如 MLP）的预测精度
3. 对比 CI 与 CD 策略在多变量时序预测（如电力数据）中的效果
4. 用 PathTST/iTransformer 模型处理长序列时序数据，计算预测误差

九、时序表示学习与通用模型（文档 8）

记忆类

1. 自监督时序表示学习方法（TS2Vec、CoST、SimMTM）的核心思想
2. TS2Vec 的时间对比损失、实例对比损失定义
3. CoST 的趋势 / 季节解纠缠表示及对比损失类型（时间域、频率域）
4. 通用模型（TimesNet、Meta-Transformer）的适用任务范围

推导类

1. TS2Vec 对比损失函数（ $-\log \frac{\exp(r_{i,t} \cdot r_{i,t}')}{\sum_j (\exp(r_{i,t} \cdot r_{j,t}') + \mathbb{1}_{\{i \neq j\}} \exp(r_{i,t} \cdot r_{j,t}))}$ ）推导

2. CoST 频率域对比损失（振幅、相位）的计算推导
3. SimMTM 的重构损失与对比损失联合优化推导

实操类

1. 用 TS2Vec 预训练时序表示，用于下游任务（如分类、异常检测）
2. 用 CoST 解纠缠时序数据的趋势与季节成分，可视化表示空间
3. 用 TimesNet 模型处理多任务（预测 + 分类），评估通用性能
4. 用 Meta-Transformer 处理多模态数据（如时序 + 文本），提取共享特征

十、时间序列评价与预处理（文档 11）

记忆类

1. 缺失值处理方法（插值、模型预测、删除）的适用场景
2. 异常值检测方法（ 3σ 、IQR、LOF）及处理方式（替换、删除、修正）
3. 数据转换方法（Box-Cox、归一化 / 标准化）的公式及作用
4. 评价指标（MAE、MSE、SMAPE、MAPE、OWA）的公式及特点

推导类

1. Box-Cox 变换的导数计算（验证 $\lambda=0$ 时为对数变换）
2. SMAPE 的对称性推导（ $\frac{2|y - \hat{y}|}{|y| + |\hat{y}|}$ 对 y 和 \hat{y} 对称）
3. MASE 的基准误差（朴素预测误差）计算推导

实操类

1. 对含缺失值的时序数据（如气象数据）用线性插值 / ARIMA 预测填充
2. 用 3σ /IQR 方法检测时序数据中的异常值，并进行修正
3. 对异方差序列（如销量数据）进行 Box-Cox 变换，验证方差稳定性
4. 计算不同预测模型的 MAE、MSE、SMAPE，对比模型性能

十一、时间序列基础预测方法（文档 12）

记忆类

1. 朴素预测、带漂移的朴素预测、季节朴素预测的公式及适用场景
2. 简单滑动平均（SMA）、加权滑动平均（WMA）的计算方法
3. 指数平滑方法（SES、Holt、Holt-Winters）的递推公式
4. 趋势外推方法（线性、指数、多项式）的模型形式

推导类

1. 简单指数平滑（SES）的递推公式（ $S_t = \alpha y_t + (1 - \alpha)S_{t-1}$ ）推导（展开为历史数据加权和）
2. Holt 线性趋势平滑的趋势更新公式（ $T_t = \beta(S_t - S_{t-1}) + (1 - \beta)T_{t-1}$ ）推导
3. 线性趋势外推的最小二乘估计（a、b 的计算）推导
4. 指数趋势外推的对数转换推导（将指数模型转为线性模型）

实操类

1. 对无趋势无季节序列用 SES 预测，调整 α 观察预测效果
2. 对含线性趋势的序列用 Holt 方法预测，计算预测误差
3. 对含季节趋势的序列用 Holt-Winters 方法（加法 / 乘法）预测
4. 对长期趋势序列（如人口数据）用线性 / 多项式趋势外推预测以上考纲及知识点分类完全覆盖 11 个文档的核心内容，兼顾概念理解、数学推导与实践应用，符合优秀高校课程要求；分类部分明确“记忆 - 推导 - 实操”层次，便于学生针对性学习。

（注：文档部分内容可能由 AI 生成）